Perguntas Frequentes: Do Modelo em Madrid ate Amsterdam

Respostas detalhadas as 7 perguntas sobre features, validacao, metricas e transferencia de modelo

---

1. O que sao "features"? Sao dados?

Sim, sao dados - mas **dados derivados**, nao os dados brutos. A refletancia bruta (Blue, Green, Red, NIR, SWIR1, SWIR2) e o dado primario, medido pelo satelite. Uma *feature* e um numero **calculado** a partir desses dados brutos para resumir um padrao util.

Exemplo concreto: **NIR_early_mean** nao e uma medicao - e a media da banda NIR de um pixel, calculada so com os anos 1984-2003. Das 60 features do modelo, nenhuma e "crua": todas sao estatisticas (media, desvio-padrao) calculadas sobre a serie temporal de 40 anos de cada pixel.

2. O que e a matriz de confusao? (Nao e a matriz de 60 colunas)

Sao coisas diferentes:

	O que e	Tamanho
Matriz X (features)	1 linha por pixel, 60 colunas de atributos. E a entrada do modelo.	Ex.: 76.263 x 60
Matriz de confusao	1 linha por classe REAL, 1 coluna por classe PREVISTA. Mostra onde o modelo acerta e onde erra.	Sempre 4x4 (4 classes)

Cada celula (i, j) da matriz de confusao conta quantos pixels que REALMENTE sao da classe i foram PREVISTOS como classe j. A diagonal = acertos. Fora da diagonal = erros - e e ai que se ve, por exemplo, a Classe 1 confundida com a Classe 2.

3. O modelo foi validado em Amsterdam? Sim - com detalhe

Foi validado de duas formas, porque Amsterdam tem poucos rotulos disponiveis (esse e o ponto central do desafio):

a) Zero-shot (nenhum rotulo de Amsterdam usado) - mede o "pior caso":

Classe	Precisao	Recall	F1
1 (Pre-1945)	0,428	0,102	0,164
2 (1945-1984)	0,366	0,880	0,517
3 (1984-2004)	0,753	0,105	0,185
4 (2004-2024)	0,601	0,436	0,505

Macro-F1 = 0,343 | Accuracy = 40,3%

b) Few-shot com protótipos (5 a 200 rótulos/classe, repetido 10x com amostras diferentes para medir variância):

Amostras/classe	Macro-F1
5	0,544 +/- 0,032
25	0,599 +/- 0,018
100	0,613 +/- 0,010
200	0,615 +/- 0,004

Nao foi feita uma validacao cruzada k-fold classica em Amsterdam (nao ha dados suficientes rotulados para isso) - em vez disso, sortearam-se repetidamente subconjuntos aleatorios do "support set", o que cumpre o mesmo papel: estimar media e variancia do desempenho.

5. Macro-F1 e "precisao"? Cuidado com o termo

Nao e exatamente "% de acerto". Sao conceitos relacionados mas diferentes:

- **Accuracy** = % total de pixels classificados corretamente (nao distingue classes).
- **F1 por classe** = media harmonica entre precisao (dos que o modelo disse ser classe X, quantos realmente sao) e recall (dos que realmente sao classe X, quantos o modelo capturou).
- **Macro-F1** = media do F1 das 4 classes, dando peso IGUAL a cada classe, mesmo que uma tenha muito mais pixels que outra.

Por isso, no zero-shot, a accuracy (40,3%) e o macro-F1 (34,3%) sao diferentes: a accuracy e "inflada" porque a Classe 2 (a maior) tem recall de 88% e "carrega" o resultado; o macro-F1 penaliza o facto de as Classes 1 e 3 quase nao serem identificadas (recall ~10%). **Usa macro-F1 quando as classes forem desbalanceadas - e sempre o caso aqui.**

6. Qual modelo recomendo (e e o que foi aplicado na pergunta 4)

Recomendacao: XGBoost para o modelo base (Stage 1, Madrid) + manter o classificador de protótipos (nearest-centroid) para a transferencia (Stage 2, Amsterdam). Nao recomendo SVM nem rede neural aqui. Justificacao:

Opcao	Por que sim / nao
Random Forest (original)	Baseline correta, mas o proprio notebook admite que e "sem otimizacao" - da para melhorar.
XGBoost (recomendado)	Em dados tabulares com muitas features correlacionadas, gradient boosting normalmente supera Random Forest, com melhor controlo de overfitting (regularizacao) e de desequilibrio de classes. Mantem a interpretabilidade (feature importance).
SVM	Com 76 mil pixels e 60 features seria lento a treinar (kernel nao-linear escala mal), nao da probabilidades bem calibradas por padrao, e nao traz vantagem clara aqui.
Rede neural (MLP/embeddings)	Poderia em teoria aprender uma representacao melhor (sugestao "de luxo" do notebook: triplet loss), mas exige muito mais dados, tuning e risco de overfitting - e o desafio recompensa desempenho com POUCOS rotulos (5-200/classe). Uma rede complexa tende a perder para o prototipo simples nesse regime.
Prototipo (mantido)	E o mecanismo certo para a TRANSFERENCIA em si - funciona bem com 5-25 amostras/classe, onde SVM/rede neural falhariam. Nao depende de qual classificador (RF ou XGBoost) foi usado no Stage 1.

Ou seja: nao trocar a arquitetura de transferencia (protótipos) - e ela que resolve o problema de "poucos rotulos" do desafio. O ganho de precisao deve vir de melhorar o modelo de Madrid (XGBoost), nao de um classificador mais complexo no lado de Amsterdam.

4 e 7. Proximo passo pratico: da validacao em Madrid ate Amsterdam

A resposta a pergunta 4 esta correta: o primeiro passo APOS treinar em Madrid e VALIDAR o modelo dentro da propria Madrid, antes de sequer tentar transferi-lo. O script completo (**proximo_passo_madrid_para_amsterdam.py**, entregue em separado) segue esta ordem:

Parte	O que faz	Responde a
A	Validacao cruzada em Madrid (5-fold x 5 repeticoes) com XGBoost - confirma que o modelo generaliza bem antes de avancar	Pergunta 4 (1o passo)
B	Treina o modelo final XGBoost com TODOS os dados de Madrid	Pergunta 4 (2o passo)
C	Zero-shot: aplica o modelo de Madrid a Amsterdam sem nenhum rotulo local - mede o "pior caso"	Pergunta 4 (3o passo) / Pergunta 3
D	Few-shot: calcula protótipos de classe com poucos rotulos de Amsterdam (5 a 200/classe) e classifica por centroide mais proximo	Pergunta 4 (4o passo, aplicacao final) / Pergunta 6
E.1	Matrizes de confusao lado a lado (Madrid CV vs. Amsterdam zero-shot)	Pergunta 7 - matriz de confusao
E.2	Mapa espacial 2D (px_key, py_key): preto=acerto, vermelho=erro	Pergunta 7 - mapeamento espacial
E.3	Mapas de entropia de Shannon e divergencia KL da classe real (incerteza)	Pergunta 7 - analise de incerteza
E.4	Grafico de importancia de variaveis (feature importance) do XGBoost	Pergunta 7 - importancia das variaveis

Detalhe tecnico importante

A Parte D (protótipos) NAO usa o XGBoost. Os protótipos sao calculados diretamente sobre os 60 atributos padronizados (X). E por isso que o modelo escolhido no Stage 1 (Random Forest ou XGBoost) so afeta o zero-shot - a transferencia em si e sempre feita da mesma forma, independentemente do classificador usado em Madrid.

O que cada parte do diagnostico (Parte E) revela na pratica

- **E.1 - Matrizes de confusao:** permite ver diretamente se a confusao classica Classe 1 <-> Classe 2 se confirma nos teus dados (ambas anteriores a 1984, sem sinal direto de construcao visivel no satelite).
- **E.2 - Mapa espacial:** reconstroi a cidade em 2D a partir de px_key/py_key; mostra se os erros se concentram em bairros especificos (util para priorizar rotulagem manual nessas zonas).
- **E.3 - Incerteza:** entropia de Shannon (0 a 2 bits) mostra onde o modelo esta confiante vs. inseguro; a divergencia KL da classe real mostra onde o modelo erra COM confianca (o caso mais preocupante).
- **E.4 - Importancia de variaveis:** confirma quais das 60 features realmente pesam nas decisoes do modelo - util para simplificar o pipeline ou orientar nova engenharia de atributos.

Nota: o script nao pode ser executado ate ao fim neste ambiente porque os ficheiros reais (madrid_train.parquet, amsterdam_data.parquet) nao foram enviados - apenas os notebooks. Corre-o no teu ambiente local/Colab, onde tens o preprocessed_data.pkl gerado pelo Notebook 3.